

空間情報の抽象化に基づく LLM 活用による 道案内の目印地物特定と説明文生成

松本 美風[†] 中西 勇輝^{††} 橋口 友哉^{††} 大島 裕明^{†,††}

[†] 兵庫県立大学 社会情報科学部 〒651-2197 兵庫県神戸市西区学園西町 8-2-1

^{††} 兵庫県立大学 情報科学研究科 〒651-2197 兵庫県神戸市西区学園西町 8-2-1

E-mail: [†] fa22n084@guh.u-hyogo.ac.jp, ^{††}{ad24v042, af24c011}@guh.u-hyogo.ac.jp, ohshima@ai.u-hyogo.ac.jp

あらまし 本研究では、大規模言語モデル (LLM) を用いて OpenStreetMap (OSM) の地図情報を解釈させ、目印地物を活用した人間らしい道案内文を生成する手法を提案する。現在のナビゲーションシステムでは、「300m 先を右折」や「北に向かって進む」、「国道 99 号を左折」のように距離や方角、道路名に基づく道案内が主流である。しかし、このような案内は、ユーザの距離感や方角の認識に依存しており、直感的ではない。これに対して、人間が行う道案内は、目立つ建物を基準とし、相対的な位置関係を用いて説明するという特徴がある。そこで本研究では、地図情報を SVG 形式のテキストに変換して LLM に入力し、実際の道案内データを用いてファインチューニングを行う手法を提案する。本研究では、地図を画像として入力する視覚言語モデル (VLM) との比較によるテキスト入力形式の有効性の検証および汎用モデルに対するファインチューニングの有効性の検証を行った。実験の結果、地図情報の理解において、SVG 形式のテキスト入力は画像入力と比較して高い正解率を示すことを明らかにした。また、提案手法によるファインチューニングを行うことで、未学習のモデルと比較して適切な目印地物を選択する能力が大幅に向上することを確認した。

キーワード 地理データ, ランドマーク, LLM

1 はじめに

既存のカーナビゲーションシステムや地図アプリケーションでは「300m 先を右折」のように距離や方角に依存した定量的な案内を行うことが多い。しかし、人間が実際に道を説明するときには「コンビニの角を右に曲がる」といった、周囲の中で目立つ建物や施設を目印として用いることが一般的である。人間は、こうした視認性の高い地物を移動の手がかりとして利用することで、複雑な空間認知の負担を軽減している。本研究では、このように道案内の基準として用いられる建物や施設を**目印地物**と呼ぶこととする。目印地物の例としては、コンビニエンスストアやガソリンスタンドが挙げられる。このような目印地物を用いた道案内は、距離や方向感覚が曖昧な状況でも理解しやすく、直感的であるという特徴がある。このような移動者の視点と視認可能な地物との相対的な位置関係を使った案内のことを「人間らしい道案内」と定義する。この人間らしい道案内の特徴をナビゲーションシステムに取り入れることができれば、距離や方角などに基づいた案内ではなく、より自然で直感的に理解できる道案内が実現できると考える。

近年、大規模言語モデル (LLM) の発展により、言語による高度な推論や文章生成が可能となっている。しかし、LLM はテキスト処理に特化しており、幾何学的な位置関係を直接解釈することは困難であるとされている [19]。そこで本研究では、地図情報を LLM が理解可能な SVG 形式のテキストに変換することでこの課題を解決し、適切な目印地物を使った道案内文

を生成する方法を提案する。

本研究の目的は、地図と地物情報から道案内に有用な目印地物を抽出し、それらを活用して人間らしく理解しやすい道案内文を生成する手法を開発することである。具体的には、地図データベースに含まれる地物情報を LLM が理解可能な形式に変換し、LLM を用いて道案内文生成の学習を行う。なお、本研究では利用可能な地図データとして、OpenStreetMap (OSM) を対象とする。提案手法により、LLM が地図の空間情報を正しく理解し、自然な道案内文を生成できることを示す。

本研究では以下の 2 つのリサーチクエスション (RQ) を設定し、検証を行う。

RQ1: 地図情報のモダリティによる理解能力の差異

地図を視覚的な「画像」として入力する場合と、構造化された「テキスト」として入力する場合において、LLM の地図理解および推論能力にどのような差異が生じるかを明らかにする。特に、グラフ構造としての地図解釈において、テキスト入力が画像入力と比較してどの程度有効であるかを検証する。

RQ2: ファインチューニングによる特化手法の有効性

汎用的な LLM に対し、地図読み取りタスクに特化したファインチューニングを行うアプローチが、目印地物の選択において有効であるかを検証する。

また、本研究の貢献は以下の 3 点である。

- **構造化データによる地図理解手法の提案:**

地図を画像ではなく SVG 形式のテキストとして LLM

に入力することで、画像入力を用いる場合と比較して、地物の名称や位置関係をより正確に認識できることを示した (RQ1 への回答)。

- **軽量な学習による特化モデルの有効性の検証:**

LoRA を用いた効率的なファインチューニングにより、計算コストを抑えつつ、目印地物の選択性能を向上させることが可能であることを示し、本タスクにおける学習手法の有効性を明らかにした (RQ2 への回答)。

- **道案内評価用データセットの構築:**

具体的なコンビニや飲食店等の名称を含む 500 件の道案内評価データセットを独自に構築した。

2 関連研究

本節では、まず人間が空間認知においてランドマークをどのように利用しているかについて触れ、その重要性を述べる。次に、地図データを用いて自動で道案内文を生成する先行研究とその課題について述べる。最後に、近年の LLM や視覚言語モデル (VLM) を用いた空間認知に関する研究について整理し、本研究の立ち位置を明確にする。

2.1 ランドマークの重要性

人間が空間を移動する際、ランドマークは自身の位置を特定し、空間を理解するために重要な役割を果たしている。都市計画の分野において Lynch [9] は、ランドマークは人間が脳内で認知地図を形成する際の主要な構成要素の一つであると提唱した。また、Yesiltepe ら [20] は出発地から直接見えない目的地に到達することを目指す、目的志向的な移動であるウェイファインディングにおいて、ランドマークが人々の空間知識を整理し、特定の目的地に対する自分の位置を容易に把握するのに役立つと述べている。

これらの知見は、人間が絶対的な座標ではなく、特徴的な地物との相対的な位置関係によって環境を理解していることを示唆している。

ナビゲーション研究の分野では、ランドマークの役割とその定義についてより具体的な議論が行われている。Sorrows ら [17] は、ランドマークを「環境内において認識可能であり記憶に残る特性を持つ地物」と定義している。また、道案内記述の観点からは Denis ら [2] が、ランドマークは移動者が交差点など方向転換の重要な点において、正しい経路にいることを確認するための中間ゴールとして機能すると述べている。この確認の機能こそが、ナビゲーションの確実性を担保するものである。「300m 先を右折」というような距離や方角のみの指示はこの機能を持たないため、道案内としては不完全であるといえる。

実際に具体的なナビゲーションタスクにおいてもその有効性が示されている。Lovelace ら [13] による比較実験では、距離や方角のみに基づく案内よりも、ランドマークに基づく道案内のほうが移動者にとって理解しやすく、迷う回数が減少することを示している。Denis [1] も、人間が生成する道案内文を分析し、単なる移動の指示だけでなく、ランドマーク記述が含まれ

ることで、移動者がより効率的に経路を辿れることを明らかにした。

さらに、Michon ら [14] は、実際に、人間が作成する道案内文を分析し、ランドマークの提示は経路上に均等に行われるのではなく、特に方向転換が必要な意思決定地点に集中するということを明らかにした。こうした地点において、ランドマークの言及が不可欠であると結論づけている。

本研究ではこれらの知見に基づき、特にナビゲーションの要となる交差点において、適切なランドマークを用いた道案内文生成に焦点を当てる。

2.2 地図データを用いた道案内生成

OSM などのオープンな地図データを用いて、ランドマークを含む案内文を生成する試みは以前から行われている。Drager ら [4] は OSM のデータのみを用いて、カーナビゲーションの経路指示を生成するシステム Virtual Co-Pilot を提案した。彼らは OSM のタグ情報に基づいてランドマーク候補を抽出し、テンプレートを用いることで「教会の後ろで左折」というような自然な道案内の生成に成功している。

また、Duckham ら [5] は、最短経路ではなく、最も説明しやすい経路を探索するアルゴリズムを提案し、ランドマークの顕著性に基づいた道案内生成の有効性を示している。

さらに、近年では機械学習を用いたアプローチも提案されている。Schumann ら [16] は、道案内生成を「Graph-to-Text」問題として定式化し、地図のノードとエッジをニューラルネットワークに直接学習させることで、正確なナビゲーション生成が可能であることを示した。この研究は、地図を画像ではなく構造化データとして扱うことの有効性を示唆する重要な成果である。

しかし、Drager らのようなルールベースの手法は柔軟な表現生成に限界があり、Schmitt らのような専用モデルを学習させる手法は、ゼロからの学習に膨大な計算資源と時間を必要とする課題がある。

これに対して、本研究では学習済みの LLM と SVG 形式を用いることで、厳密なルール定義やゼロからの構造学習を必要とせず、LLM が持つ豊富な言語知識と推論能力を活用した、人間らしい多様な表現による道案内生成を実現する。

2.3 視覚言語モデル (VLM) と構造化データによる地図理解

近年、LLM や VLM の発展に伴い、これらのモデルをナビゲーションに応用する研究が増加している。Ung ら [19] は、OSM から生成した地図画像を用いて、大規模視覚言語モデル (LVLM) の地図読解能力を評価するベンチマーク CartoMapQA を提案した。彼らは、地図記号の識別、距離推定、最短経路探索という 3 つのタスクにおいて評価を行った。Gemini 2.5 Pro や GPT-4V などの高性能なモデルであっても、地図上の細かい記号の認識や、正確なルート追跡には課題が残るとされている。

さらに、Tong ら [18] は、現在の VLM に用いられる CLIP 等の視覚エンコーダにおける構造的な課題を指摘している。これらのモデルは、画像の大域的な意味理解には優れる一方で、空

間的な位置関係や幾何学的な詳細情報を抽象化する傾向があると述べている。実際に、現在の VLM は「円が重なっているか」といった単純な幾何学的関係の認識において、人間と比較して著しく低い精度にとどまることが報告されている。これは、画像をピクセル集合のラスター形式として入力する限り、モデルの構造上、正確な座標や位置関係の把握には限界があることを示唆している。

これに対して、視覚情報を LLM が解釈しやすい形式に変換することで推論能力を向上させる手法が提案されている。Liang ら [11] は、ロボット制御において自然言語による推論よりも、プログラミング言語のような論理的、数学的な構造を介して推論を行うほうが、空間的な推論や数値計算において高い精度を達成することを示している。

Liu ら [12] は、図表やグラフの画像理解において画像をラスター形式で入力するよりも、構造化されたテキストに変換してから LLM に入力したほうが推論精度が向上することを示した。

同様に、Lee ら [10] は、Web ページのスクリーンショットなどの画像を HTML などの構造化データに変換する事前学習手法「Pix2Struct」を提案した。彼らは、Web ページを構造化されたテキストに変換して入力することで、下流タスクにおけるモデルの推論精度が大幅に向上することを実証している。

Fatemi ら [6] は、ノードとエッジで表されるグラフ構造を LLM に理解させる際にグラフを可視化した画像を入力するよりも、隣接リストなどのテキスト形式で構造記述を与えたほうが推論能力が向上することを明らかにしている。地図データもまた、交差点をノード、道路をエッジとするグラフ構造とみなすことができる。地図データをラスター形式の画像として扱うよりも、Scalable Vector Graphics (SVG) という構造化されたテキストとして扱う本研究のアプローチは Fatemi らの知見とも整合するものであり、LLM にとってより理解しやすい形式であるといえる。

これらの知見は地図画像においても、ラスター形式の画像を用いるよりも、構造化されたベクターデータを用いるほうが、モデルにとって理解が容易であることを示唆している。

また、場所説明に関する研究として Muron ら [15] は、OSM データと LLM を組み合わせたハイブリッド手法を採用している。彼らは、クラウドソーシングで収集した人間が書いた場所説明文のデータを分析し、人間はランドマークを選択するときに、単に距離が近いものを選ぶのではなく、隣接や対面といった位置関係をもつ地物を優先的に使用する傾向があることを明らかにした。彼らはこの知見に基づいて、ランドマークの顕著性と位置関係をスコア化するルールベースのアルゴリズムを構築し、その結果を LLM に入力して自然な文章を生成している。

これに対して、本研究では明示的なルールは用いず、SVG という構造化データを LLM に入力することで、地物の選択から案内文生成までをモデル自身に行わせる手法をとる。

以上の背景から、本研究では地図を画像としてではなく、LLM が処理しやすい構造化されたテキストとして SVG を扱う。こ

れにより視覚的な認識エラーを避け、高性能な道案内生成の実現を目指す。

3 問題定義とデータ

本節では、本研究が扱うタスクの定義と、データセット作成に利用したデータについて述べる。

3.1 問題定義

本研究の目的は、システムが交差点周囲の地図情報を解釈し、最も適切な目印地物を選択したうえで、それを用いた自然な道案内文を生成することである。本タスクの入出力を以下に示す。

- **入力**
 - **地図情報**

交差点を中心とした一定範囲内に存在する地物 (POI) や道路ネットワークの情報である。これには、地物の名称や、コンビニや銀行といったカテゴリ、各地物の位置情報が含まれる。
 - **移動の向き**

「右折」「左折」といった、交差点における移動の指示である。
- **出力**
 - **目印地物**

入力された地物の中から、説明に最も適した地物を 1 つ選択する。
 - **案内文**

目印地物と移動の向きを組み合わせ、`[目印地物]`の手前を右に曲がる」のようなテキストを生成する。

3.2 地図データベースと OpenStreetMap

地図データベースは一般に、建物や道路などを表すジオメトリと、それらの名称やカテゴリを表す属性情報から構成される。本研究が目指す人間らしい道案内においては、地物の属性情報が重要となる。

そこで、地物の詳細な属性情報が利用可能であり、世界規模で利用されている地図データベースとして、OpenStreetMap (OSM)¹を採用する。OSM は、世界中のボランティアによって作成され、公開されている無料の地図データベースである。OSM のデータは、主にノード、ウェイ、リレーションの 3 つの要素で構成されている。本研究では主にノードとウェイを扱う。ノードは、緯度経度を持つ点であり、主に、信号機、バス停、店舗などの Point of Interest (POI) や交差点などを表す。ウェイは道路のような線や建物の輪郭のような閉じた領域を表す。

これらの要素には `key=value` 形式のタグと呼ばれる属性情報が付与されている。例えば、ある建物を示すノードに対して `shop=convenience` というタグが付与されていれば、その施設がコンビニエンスストアであることを意味する。本研究では、これらのタグ情報を地物の種類や名称を特定する手がかりとし、

1: <https://www.openstreetmap.org/>

LLM に入力する地図情報として用いる。

3.3 道案内テキストの収集

LLM で人間らしい道案内文生成を実現するためには、地図情報と、人間が実際に記述した理想的な案内文がペアになった学習データが必要である。

本研究では、株式会社リクルートが提供するホットペッパーグルメサーチ API²（以下グルメサーチ API とする）を用いて、全国の飲食店情報 136,490 件を取得した。取得したデータには、店舗の名前、住所、緯度経度、最寄り駅などに加え、店舗への行き方を示すアクセス情報（以下 access 文とする）が含まれている。

この access 文は、店主などが来店客のために記述した実用的な案内文である。具体的には「コンビニの角を右に曲がる」「交番の手前を左折する」といった、目印となる地物と右左折の動作を組み合わせた人間らしい表現が用いられている。このように、地物と位置関係、進行方向が明確に紐づけられたテキストを含むため、本研究の学習データとして適している。

4 データセットの構築

本節では、収集した生の道案内テキストから、本研究のタスクに適した学習および評価用データセットを構築する手順について述べる。

4.1 データセット構築の手順

収集したデータの中には、「駅から徒歩 5 分」「100m 先」といった最寄り駅からの時間や距離のみのデータも多数含まれる。本研究の目的である、目印地物を用いたナビゲーションの実現のためにこのような表現のデータは扱わない。そこで、以下の条件を用いたフィルタリングにより、学習に適したデータセットの構築を行った。

1. キーワードによる絞り込み:

access 文に「右折」「左折」の、明確な方向転換を示す動作語が含まれるデータのみを抽出した。これにより、距離や時間のみの記述など、本研究の対象外となるデータを除外した。

2. LLM による目印地物の特定:

Azure OpenAI Service で利用可能な GPT-3.5 Turbo³ を用いて、方向転換の動作に関連付けられている目印地物を抽出した。例えば「コンビニを右折」における「コンビニ」を抽出対象とした。ここで抽出された地物を、その交差点における「正解の目印地物」の候補とする。また同時に、access 文から「目印地物」と「右折、左折の移動指示」が記述されているフレーズを抜き出し、人間が記述した案内文としてデータセットに含めた。

3. OSM データベースとの自動照合:

抽出した目印地物が、OSM データベース上に存在する

かを確認するために、各店舗の緯度経度を中心として、半径 1,000m 以内に存在する地物を OSM データベースから検索した。ここでは、名称に基づく自動照合を行い、OSM データベース上の地物との紐づけを試みた。

4. 言及交差点の特定と地物情報の修正:

access 文中で言及されている交差点を特定する作業を行った。交差点の緯度経度と、進入方向を特定するために専用のツールを作成し、1 件ずつ手動で確認を行った。この際に、自動照合で紐づけができなかったデータについて、OSM データベース上に存在することが確認できた場合は、手動で正しい OSM データベースの地物との紐づけを行った。最終的に、交差点の位置、進入方向、目印地物を正しく特定できたデータのみを採用した。

このフィルタリングにより、136,490 件の道案内文から、500 件のデータセットを構築した。表 1 にデータセットの例を示す。

4.2 データセットの特徴

本研究で構築したデータセットは、以下の 3 点において独自性を持つ。

第一に、実際に店主などが作成した「人間による案内文」を収集している点である。テンプレート的な生成文ではなく、実際に使用されている多様な表現が含まれている。

第二に、案内文中に含まれる目印地物が単なる文字列ではなく、OSM データベース上の ID を持つ地物として紐づけられている点である。これにより、地図上の座標やタグ情報を活用することが可能となる。

第三に、案内文に含まれる地物が、人間が「分かりやすい」と判断して選択したものである点である。そのため、このデータセットには、「目印としての顕著性」に関する人間の暗黙知が含まれているといえる。これを学習することで、モデルは単に交差点に近い地物を選択するだけでなく、人間にとって認知しやすく、説明に適した地物を予測する能力を獲得することが期待される。

5 LLM 活用のための空間情報の抽象化

本節では、構築したデータセットを用いて LLM が地図情報を解釈して道案内文を生成する具体的な手法について述べる。

5.1 地図情報の SVG 形式のテキスト表現

LLM は数値である緯度経度情報から、地物の位置関係を直接理解することが難しい。そこで本研究では、交差点とその周辺地物の位置関係を明示するために、地図情報を正規化されたピクセル座標と構造化タグで記述する **Scalable Vector Graphics (SVG)** 形式を用いる手法を提案する。

具体的には、目印地物が存在する交差点を中心とした一定の範囲を設定し、その範囲内に存在する地物や道路情報を抽出する。抽出した情報から以下の要素を記述する。

- **名称:** 店舗や施設の固有名詞 (例: セブンイレブン)。
- **カテゴリ:** OSM のタグ情報 (例: shop=convenience)。
- **位置:** ピクセル座標。

2: <https://webservice.recruit.co.jp/>

3: <https://platform.openai.com/docs/models/gpt-3.5-turbo-16k-0613>

表 1 データセットの例

name	access	目印地物	案内文
キッチン エム	ガソリンスタンドを右折, JA 今治を左折して右手です.	ガソリンスタンド, JA 今治	ガソリンスタンドを右折, JA 今治を左折
御料理 わだつみ	ロータリーを挟んだ向かい側に渡り松屋さんを右折. ファミリーマートを左折し 50m 程入った左手.	松屋, ファミリーマート	松屋さんを右折, ファミリーマートを左折




図 1 入力 SVG のイメージ

- 交差点と道路: 交差点ノードと道路のエッジ.

5.2 対象領域の設定と SVG 生成

地図情報の取得に際して、対象領域を決定する．この領域はズームレベルと画像サイズによって決定する．

ズームレベルは地図の縮尺を表すパラメータであり、値が大きいほど狭い範囲の地図となる．本研究では、交差点周辺の地物や道路を視認するのに十分な縮尺として、ズームレベルを 18 に設定した．画像の解像度を 256 × 256 ピクセルとした場合、対象となる交差点を中心とする約 124 メートル四方の領域に相当する．

設定した領域内の道路ネットワークは、Python のライブラリである OSMnx を用いて取得する．一方で、地物の情報は OSM データベースから取得する．取得する地物は名称を持つ地物とし、その属性として amenity, shop, tourism, leisure, historic, building の 6 カテゴリの情報を利用した．

取得した道路ネットワークと地物の情報をピクセル座標に変換する．具体的には、各要素の緯度経度を、交差点を (50, 50)、小川サイクルを (51, 32)、画像の左上を (0, 0)、右下を (100, 100) となるように変換を行う．

この処理で生成される入力データのイメージを図 1 に示す．この図は正規化された 100 × 100 の座標空間における地物と道路の位置を可視化したイメージである．また、図 2 は、このデータを実際に LLM に入力する際の例である．data-name などの属性として地物の名称や種別を入力している．

5.3 目印地物の抽出と案内文生成のプロンプト設計

作成した SVG データを LLM に入力し、適切な案内文を出力させるために、本研究では図 3 に示すプロンプトを設計し



図 2 入力 SVG の構造例

た．このプロンプトでは、SVG タグの定義を与えたうえで、タグ構造に基づいた解析を指示している．また、いきなり案内文を生成させるのではなく、「ルートの確認」→「地物の探索」→「案内の作成」という段階的な思考の手順を指示している．

また、本研究では比較実験として地図を画像として入力した場合の評価も行う．そのために用いるプロンプトを図 4 に示す．入力データには、同じ SVG データを 256 × 256 ピクセルの PNG 画像としてレンダリングしたものを用いる．このプロンプトでは、画像内の「線の色」や「文字情報」といった視覚的な位置関係に基づいた解析を指示している．

6 実験設定

本節では、提案手法であるテキスト入力の有効性を検証するための実験設定について述べる．比較対象として同一の地図情報を画像として入力する実験も行い、テキスト表現と視覚表現の性能比較を行う．

なお、学習における正解データは、グルメサーチ API から取得したデータの access 文中で人間が使用していた目印地物とする．例えば、地図上に「セブンイレブン」と「ガソリンスタンド」が存在する状況において、元の文が「セブンイレブンを右折」であった場合、正解は「セブンイレブン」となる．これにより、モデルは地図上の多数の地物の中から、ランダムに地物

```
# 役割と目的
あなたは高度な空間認識能力を持つナビゲーション AI 解析システムです。
提供される SVG 形式の地図データを読み解き、指定された進行方向に対して
適切な目印となる地物を特定することが使命です。

# 出力フォーマット
必ず以下の JSON フォーマットで出力してください。 Markdown のコードブ
ロック ("```json ... ```) は不要です。 生身の JSON データのみを出力し
てください。

{
  "landmark": "抽出した data-name 属性の値",
  "instruction": "日本語の案内文"
}

# SVG データのスキーマ定義（重要）
入力される SVG は以下のカスタム属性を含みます。 解析時はこの定義に従
ってください。
1. 'data-name':
  - 地物の正式名称です。 出力の 'landmark' フィールドには、この値を一
    字一句変更せずに使用してください。
2. 'data-category':
  - 地物の種類（例: 'convenience', 'school', 'restaurant'）。
3. 'data-turn_direction':
  - この地図におけるナビゲーションの進行方向（例: '右折', '左折'）。
4. 'data-type':
  - '<line>' 道路を表す。
  - 'start': 交差点への進入ルート。
  - 'goal': 交差点からの脱出ルート。

# 重要：地物名の抽出ルール（厳守）
1. 完全一致での抽出：
  - SVG 内の <g ... data-name="ここにある文字列"> を抽出してくださ
    い。
2. 存在しない地物の禁止：
  - SVG データ内に data-name 属性として存在しない名称は絶対に出力しな
    いでください。

# タスク指示
ユーザは現在、ある交差点に差し掛かっています。 以下の SVG 地図情報と移
動指示に基づき、「曲がるときに、どの建物や施設が目印になるか」を特定し、
案内文を作成してください。

## 分析手順
1. ルートの確認：
  - <g id="navigation_vectors"> の start から goal への角度を確認
    し、交差点の形状と曲がる方向を把握します。
2. 地物の探索：
  - <g id="pois"> 内の地物座標を確認します。
  - SVG の座標系 (0-100) において、交差点中心 (cx, cy) との相対位置関
    係を見てください。
  - data-category を参照し、地物のカテゴリを参考にしてください。
3. 案内の作成：
  - ユーザ視点で「右手の角にある [landmark] を目印に…」のように案内
    します。

# 入力データ
- 移動アクション: {turn_dir}
- 地図データ (SVG): ```xml {svg_content} ```
```

図 3 テキスト入力の地物選択プロンプト

を選ぶのではなく、人間が道案内において選びやすい地物の傾向を学習する。

6.1 実験に用いるベースモデル

提案手法の有効性を検証するために、以下の 3 つのモデルに対してファインチューニングを行い、評価する。

- ELYZA-Thinking-1.0-Qwen-32B
- Llama-3-ELYZA-JP-8B
- Gemma3:27B

また、比較対象として、学習を行っていない上記のモデルのベースモデルに加えて、以下のモデルも用いて評価を行う。

- Llama4
- GPT-5.2

```
# 役割と目的
あなたは高度な視覚認識能力を持つナビゲーション AI です。 提供された「地
図画像 (PNG)」を視覚的に解析し、指定された進行方向に対して適切な目印
となる地物を特定して案内文を作成してください。

# 出力フォーマット
必ず以下の JSON フォーマットで出力してください。 Markdown のコードブ
ロックは不要です。

{{
  "landmark": "画像内から読み取ったランドマークの名称",
  "instruction": "日本語の案内文"
}}

# 画像の視覚的定義
画像内の要素は以下のルールで描画されています。 この色と配置を基準に判
断してください。
1. ルート情報：
  - 緑色の線・点: スタート地点（交差点への進入ルート）。ここから出発し
    ます。
  - 青色の線・点: ゴール地点（交差点からの脱出ルート）。ここへ向かいま
    す。
  - 赤色の点: 交差点の中心。
2. ランドマーク (POI)：
  - 灰色の丸: 建物の位置。
  - 黒色のテキスト: その建物の名称。
  - 注記: 画像内に文字として書かれている名称のみを「目印地物」として
    認識してください。

# 重要：ランドマーク名の抽出ルール
1. OCR (文字認識) の厳守：
  - 画像内の黒いテキストを正確に読み取ってください。
  - 画像に書かれていない建物を想像して出力することは禁止です。

# タスク指示
ユーザは現在、緑色のルート (Start) から交差点に入り、青色のルート
(Goal) へ抜けようとしています。 画像と以下の移動アクションに基づき、案
内文を作成してください。

## 分析手順
1. ルート確認: 画像上の「緑」から「青」への流れを目で追い、曲がる
  方向（右折・左折など）を視覚的に確認してください。
2. 目印の特定: 「文字が書かれた地物」を探してください。
3. 案内の作成: その地物を目印にして、「右手の角にある [landmark] を
  右に曲がります」のように自然な日本語を作成してください。

# 入力データ
- 移動アクション: {turn_dir}
```

図 4 画像入力の地物選択プロンプト

表 2 各モデルのファインチューニング設定			
Parameter	ELYZA-JP-8B	ELYZA-Thinking	Gemma3:27B
Batch Size	64	8	2
Epochs	98	24	9

6.2 学習設定

ファインチューニングには、計算コストを節約するため Low-Rank Adaptation (LoRA) [8] および Quantized Low-Rank Adaptation (QLoRA) [3] を適用した。実装には Unsloth ライブラリ [7] を用いた。

すべてのモデルにおいて共通して、LoRA のランク r は 16、アルファ α は 16、学習率は 2×10^{-5} に設定した。また、最適化手法には adamw_8bit を採用し、学習率スケジューラは constant とした。モデルごとに異なるバッチサイズやエポック数を表 2 に示す。

6.3 評価指標

生成された道案内文を評価するために、以下の指標を用いる。

- 正解率 (Accuracy): テストデータ 100 件に対して、LLM が出力した地物が正解の目印地物と一致した割合とする。

表 3 入力形式の違いによる正解率の比較 (RQ1)

Model	Image (PNG)	Text (SVG)
GPT-5.2	34%	34%
Gemma3:27B	14%	27%
Llama4	21%	25%
Llama-3-ELYZA-JP-8B	N/A	25%
ELYZA-Thinking-1.0-Qwen-32B	N/A	24%

7 実験結果と考察

ベースモデルと本タスク向けに構築したデータセットで学習したモデルの比較を行う。これにより、学習によって目印地物特定の正解率が向上するかを検証する。また、学習を行っていない他の代表的な LLM と性能を比較することで、本タスクの難易度や、ファインチューニングしたモデルが既存の汎用モデルに対してどの程度の優位性を持つかを明らかにする。

- Llama4
- Llama-3-ELYZA-JP-8B
- ELYZA-Thinking-1.0-Qwen-32B
- GPT-5.2
- Gemma3:27B

7.1 入力形式の比較 (RQ1)

まず、地図情報を画像として入力した場合と、テキストとして入力した場合の正解率を比較した結果を表 3 に示す。なお、VLM (Vision Language Model) ではないモデルについては、画像の入力は行わず、テキスト入力のみの結果を示している。

表 3 より、Gemma3:27B などの高性能モデルにおいて、画像入力と比較して、テキスト入力は同等以上の正解率を示している。特に Gemma3:27B では、テキストの入力では 27 % の正解率を示した。これは、地図画像を視覚的に解釈するよりも、構造化されたテキストとして解釈するほうが現在の LLM にとって理解が容易であることを示唆しており、本手法の優位性が示された。

7.2 ファインチューニングの効果検証 (RQ2)

次に、ファインチューニングによる性能の向上を検証する。学習を行った 3 つのモデルについて、ベースモデルとファインチューニング後の正解率を比較した結果を表 4 に示す。いずれも入力は SVG 形式である。実験の結果、すべてのモデルにおいて、学習によって性能が向上することが確認された。具体的には、Llama-3-ELYZA-JP-8B では、ベースモデルの 24% から 49% へ、25 ポイントの向上が見られた。また、ELYZA-Thinking-1.0-Qwen-32B では、ベースモデルの 24% から 38% へ、14 ポイントの向上が見られた。さらに、Gemma3:27B においては、ベースモデルの 27% から 53% へと、26 ポイントの向上が見られた。

以上の結果より、RQ2 で設定した「ファインチューニングの有効性」が示された。この結果は、パラメータ数が比較的少な

表 4 ファインチューニングの有無による正解率の比較 (RQ2)

Model	Base Model	Fine-tuned
ELYZA-Thinking-1.0-Qwen-32B	24%	38%
Llama-3-ELYZA-JP-8B	24%	49%
Gemma3:27B	27%	53%

いモデルであっても、ドメインに特化した学習を行うことで地図画像を理解する能力を獲得できることを示唆している。

7.3 誤り分析と課題

提案手法における誤りケースの分析を行った。ファインチューニング後のモデルが正解の目印地物を予測できなかった事例を確認したところ、モデルの認識能力不足による単純な誤りだけではなく、地物選択の曖昧性が原因である事例が確認された。

具体的には、交差点において視認性の高い地物が複数存在する状況が挙げられる。このような状況では、人間であってもどの地物を最も適切な目印とするのかという判断が個人の主観によって分かれる可能性が高い。本実験の正解データは、特定の人が作成した案内文に基づいているため、あくまで主観的な正解の一つに過ぎない。その結果、モデルが位置関係や、地物のカテゴリに基づいて客観的に妥当な地物を選択した場合であっても、正解データの文字列と完全一致せずに誤りと判定されてしまう事例があった。

8 まとめ

本研究では、地図データを用いた人間らしい道案内文の生成を目的とし、LLM が空間情報を理解するための入力表現として、地図情報を SVG 形式の構造化テキストに変換する手法を提案した。この手法により、交差点の形状や進行方向、周辺地物の配置といった空間情報を、タグの階層構造や属性値を持つテキストデータとして記述することで、LLM が論理的に空間を推論できる枠組みを構築した。

また、提案手法の有効性を検証するために、実際の店舗のアクセス情報に基づき、人間が作成した案内文と OSM データベース上の地物を紐づけたデータセットを独自に構築した。このデータセットを用いて評価実験を行った。実験の結果、画像で地図を入力する場合と比較して、提案手法である SVG 形式のテキストで入力した場合は同等以上の正解率を示すことを確認した。さらに、提案手法を用いてファインチューニングを行ったモデルは、ベースモデルと比較して正解率が向上したことを確認した。これらの結果は、SVG 形式によるテキストの入力と、ドメインに特化した学習を行うことで、LLM が地図上の空間的文脈を理解し、適切な目印地物を特定する能力を獲得できることを示している。

今後の課題として、以下の 3 点があげられる。

第一に、生成された道案内文の定性評価である。本実験では道案内の正確性を担保するために、目印地物の正解率を定量的な指標としたが、生成された文章の自然さや分かりやすさについては評価できていない。今後は、被験者を用いた人手評価な

どによる検証が必要である。

第二に、地物の視覚的な顕著性の考慮である。本手法では、地図上の位置関係とカテゴリに基づいて目印を選択している。しかし、実際の人間による道案内では、「赤い看板」や「高いビル」といった、外観の色や形状に関する情報も重要な手がかりとなる。今後はこのような地物の視覚的特徴を抽出し、SVGの属性として入力することで、より直感的で発見しやすい目印選択を目指す。

第三に、地物選択の曖昧性を考慮した評価指標の設計である。本実験の誤り分析により、道案内における目印地物の選択には「正解の非一意性」が存在することが明らかになった。そのため、1つの正解データと完全一致のみを求める現在の評価指標はモデルの実用的な性能を過小評価している可能性がある。今後はこれを考慮した新たな評価方法が必要となる。

謝 辞

本研究は、JSPS 科研費 JP25K03229, JP25K03228, JP24K03228 の助成を受けたものです。ここに記して謝意を表します。

文 献

- [1] Michel Denis. The description of routes: A cognitive approach to the production of spatial discourse. *Current Psychology of Cognition*, Vol. 16, pp. 409–458, 1997.
- [2] Michel Denis, Francesca Pazzaglia, Cesare Cornoldi, and Laura Bertolo. Spatial discourse and navigation: An analysis of route directions in the city of venice. *Applied Cognitive Psychology: The Official Journal of the Society for Applied Research in Memory and Cognition*, Vol. 13, No. 2, pp. 145–174, 1999.
- [3] Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. QLoRA: Efficient Finetuning of Quantized LLMs. In *Proceedings of the 2023 International Conference on Neural Information Processing Systems (NeurIPS 2023)*, pp. 10088–10115, 2023.
- [4] Markus Dräger and Alexander Koller. Generation of landmark-based navigation instructions from open-source data. In *Proceedings of the 2012 Conference of the European Chapter of the Association for Computational Linguistics (EACL 2012)*, pp. 757–766, 2012.
- [5] Matt Duckham, Stephan Winter, and Michelle Robinson. Including landmarks in routing instructions. *Journal of Location Based Services*, Vol. 4, No. 1, pp. 28–52, 2010.
- [6] Bahare Fatemi, Jonathan Halcrow, and Bryan Perozzi. Talk like a Graph: Encoding graphs for large language models. In *Proceedings of the 2024 International Conference on Learning Representations (ICLR 2024)*, 2024.
- [7] Daniel Han, Michael Han, and Unsloth team. Unsloth, 2023.
- [8] Edward Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-Rank Adaptation of Large Language Models. In *Proceedings of the 2022 International Conference on Learning Representations (ICLR 2022)*, 2022.
- [9] Lynch Kevin. *The Image of the City*, chapter 3, pp. 46–90. MIT Press, 1960.
- [10] Kenton Lee, Mandar Joshi, Iulia Turc, Hexiang Hu, Fangyu Liu, Julian Eisenschlos, Urvashi Khandelwal, Peter Shaw, Ming-Wei Chang, and Kristina Toutanova. Pix2Struct: Screenshot parsing as pretraining for visual language understanding. In *Proceedings of the 2023 International Conference on Machine Learning (ICML 2023)*, pp. 18893–18912, 2023.
- [11] Jacky Liang, Wenlong Huang, Fei Xia, Peng Xu, Karol Hausman, Brian Ichter, Pete Florence, and Andy Zeng. Code as Policies: Language model programs for embodied control. In *Proceedings of the 2023 IEEE International Conference on Robotics and Automation (ICRA 2023)*, pp. 9493–9500, 2023.
- [12] Fangyu Liu, Julian Eisenschlos, Francesco Piccinno, Syrine Krichene, Chenxi Pang, Kenton Lee, Mandar Joshi, Wenhui Chen, Nigel Collier, and Yasemin Altun. DePlot: One-shot visual language reasoning by plot-to-table translation. In *Proceedings of the 2023 Annual Meeting of the Association for Computational Linguistics (ACL 2023)*, pp. 10381–10399, 2023.
- [13] Kristin L. Lovelace, Mary Hegarty, and Daniel R. Montello. Elements of good route directions in familiar and unfamiliar environments. In *Proceedings of the 1999 International Conference on Spatial Information Theory (COSIT 1999)*, pp. 65–82, 1999.
- [14] Pierre-Emmanuel Michon and Michel Denis. When and why are visual landmarks used in giving directions? In *Proceedings of the 2001 International Conference on Spatial Information Theory (COSIT 2001)*, pp. 292–305, 2001.
- [15] Mikuláš Muroň, František Dařena, David Procházka, and Roman Kern. Automatically generated place descriptions for accurate location identification: a hybrid approach with rule-based methods and llm. *Spatial Cognition & Computation*, Vol. 25, No. 4, pp. 269–311, 2025.
- [16] Raphael Schumann and Stefan Riezler. Generating Landmark Navigation Instructions from Maps as a Graph-to-Text Problem. In *Proceedings of the 2021 Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (ACL-IJCNLP 2021)*, pp. 489–502, 2021.
- [17] Molly E. Sorrows and Stephen C. Hirtle. The nature of landmarks for real and electronic spaces. In *Proceedings of the 1999 International Conference on Spatial Information Theory (COSIT 1999)*, pp. 37–50, 1999.
- [18] Shengbang Tong, Zhuang Liu, Yuexiang Zhai, Yi Ma, Yann LeCun, and Saining Xie. Eyes Wide Shut? Exploring the visual shortcomings of multimodal LLMs. In *Proceedings of the 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR 2024)*, pp. 9568–9578, 2024.
- [19] Huy Quang Ung, Guillaume Habault, Yasutaka Nishimura, Hao Niu, Roberto Legaspi, Tomoki Oya, Ryoichi Kojima, Masato Taya, Chihiro Ono, Atsunori Minamikawa, and Yan Liu. CartoMapQA: A fundamental benchmark dataset evaluating vision-language models on cartographic map understanding. In *Proceedings of the 2025 International Conference on Advances in Geographic Information Systems (SIGSPATIAL 2025)*, pp. 40–453, 2025.
- [20] Demet Yesiltepe, Ruth Conroy Dalton, and Ayse Ozbil Torun. Landmarks in wayfinding: a review of the existing literature. *Cognitive Processing*, Vol. 22, No. 3, pp. 369–410, 2021.